

CIFAR-10 无限制对抗攻击竞赛 — 任务分工

项目信息

- **目标:** 在尽量不改变图片肉眼观感的情况下，让图像分类模型误分类
- **数据集:** CIFAR-10, 500 张 32×32 图像
- **评分:** $\text{Score} = 0.5 \times \text{Score_M}(\text{ASR} \times \text{SSIM}) + 0.5 \times \text{Score_H}(\text{Valid} \times \text{Quality})$
- **提交:** 每天最多 3 次，截止 6.26

阶段一：共建基础设施（Day 1-2）

所有人参与，统一基础代码。

任务	负责	产出
项目结构搭建、环境配置	A	<code>requirements.txt</code> 、目录结构
统一数据加载（500张图）	A	<code>data/loader.py</code>
SSIM 计算工具函数	C	<code>utils/metrics.py</code>
对抗样本保存 + 提交 zip 打包脚本	C	<code>utils/submission.py</code>

阶段二：并行开发（Day 3-14）

A：代理模型训练 + 基础攻击

目标: 训练多种异构代理模型，为全队提供攻击目标和迁移性基础。

任务	说明
训练 ResNet-18/34	基础架构，收敛快
训练 VGG-16	与 ResNet 架构差异大，测试迁移性
训练 DenseNet-121	第三种架构，丰富集成多样性
数据增强策略	水平翻转、随机裁剪、颜色抖动，提升模型鲁棒性
实现 FGSM	单步攻击，快速验证管线
实现 PGD	迭代攻击，作为后续攻击的基础
记录 baseline 结果	各模型在 FGSM/PGD 下的 ASR 和 SSIM

产出: `models/` 下多个权重文件 + `attacks/fgsm.py`、`attacks/pgd.py`

B：强迁移攻击研究

目标: 提升对抗样本对未知模型的迁移性，这是竞赛拉开差距的核心。

任务	说明
实现 MI-FGSM	劫量迭代攻击，提升迁移性
实现集成攻击 (Ensemble Attack)	同时对多个代理模型求梯度平均
输入变换攻击	resize、padding、JPEG 压缩等输入变换提升迁移性
消融实验	对比不同代理模型组合、变换策略对迁移攻击 ASR 的影响
攻击方法对比	FGSM vs PGD vs MI-FGSM vs Ensemble 在迁移场景下的表现

产出: attacks/mi_fgsm.py、attacks/ensemble.py、实验记录表格

C：质量控制 + 管线工程 + 调参

目标: 控制对抗样本的图像质量（SSIM），搭建完整生成管线，系统调参。


任务	说明
SSIM 感知攻击约束	在攻击中加入 SSIM 约束，平衡 ASR 和图像质量
批量生成管线	500 张图批量攻击 → SSIM 筛选 → 保存 → 打包
参数网格搜索	系统搜索 epsilon、iteration、momentum 等参数组合
质量筛选策略	对 SSIM 过低的样本做二次优化或回退
提交管理	管理每日 3 次提交额度，记录每次提交的参数和得分

产出: pipeline/generate.py、utils/submission.py、调参日志

阶段三：集成出图（Day 15-21）

任务	负责
用 A 的模型权重 + B 的攻击算法跑完整管线	C
根据提交反馈微调参数	C（B 协助）
生成最终 500 张对抗样本	C
打包提交	C

协作流程



提交节奏

- 前两周 (Day 3-14) : 每天 1-2 次, 用于验证攻击效果和调参方向
- 最后一周 (Day 15-21) : 每天 3 次拉满, 冲刺最优得分